

Apprentissage automatique non supervisé

Amira Barhoumi

amira.barhoumi@univ-grenoble-alpes.fr

Apprentissage non supervisé

- Données décrites par un ensemble de descripteurs $\{var_1, var_2, \dots, var_m\}$
- Données non-étiquetées sans classes connues à priori

$D = \{obj_1, obj_2, \dots, obj_N ; \text{ avec } \forall i \in \{1, \dots, N\}, obj_i : \text{une observation}\}$

- Chercher d'une division de ces données en catégories (groupes)
- Chercher une partition $\pi = \{D_1, D_2, \dots, D_k\}$ du corpus D tels que

$$D = \bigcup D_j; \forall j \in \{1, \dots, k\} \quad \text{et} \quad D_i \cap D_j = \emptyset$$

- Trouver la meilleure partition en fonction d'un critère de similarité sur D

	var_1	\dots	var_m
obj_1			
\dots			
obj_N			

Identification des catégories

	var_1	\dots	var_m
new			

Quelle catégorie?


- Approches de *clustering*
 - **Algorithmes de partitionnement** : construire plusieurs partitions puis les évaluer selon certains critères
exemple : k-means, k-medoids
 - **Algorithmes hiérarchiques** : créer une décomposition hiérarchique des objets selon certains critères
exemple : Classification ascendante hiérarchique
 - **Algorithmes basées sur les grilles** : diviser l'espace des objets dans une grille et estimer la densité
exemple : CLIQUE, STING

- Représentation d'un cluster :
 - Le centroïde : le vecteur moyen des objets constituant le cluster. Il peut correspondre à un élément du cluster
 - Le médoïde (médiane) : un des objets du cluster qui est proche de la notion du centroïde

Apprentissage non supervisé

- Mesures de similarité entre 2 clusters

- Lien simple (*single linkage*) : la plus petite distance entre les objets des 2 clusters
- Lien moyen (*average linkage*) : la distance moyenne entre les objets des 2 clusters
- Lien complet (*complete linkage*) : la plus grande distance entre tous les objets des 2 clusters



Lien simple



Lien moyen




Lien complet

- Algorithmes de partitionnement
 - Partitionner un corpus de N objets en K clusters
 - Méthodes heuristiques :
 - **k-means** [MacQueen, 1967] : chaque cluster est représenté par son centre
 - **k-médoïdes** (*Partition around medoids*) [Kaufman & Rousseeuw, 1987] : chaque cluster est représenté par un de ses objets


K-means

- Méthode d'apprentissage non supervisé
- Données (objets) non étiquetées
- Très utilisé pour la classification de documents, la segmentation d'images, la segmentation marketing
- Modèle de classification (*clustering*)
- Partitionnement en groupes (*clusters*)
- Mise en clusters consiste à
 - regrouper les objets similaires
 - séparer les objets dissimilaires




K-means

- Exploration des données
 - connaissance des données
 - connaissance de la nature des groupes recherchés (prototype par groupe)
- k-means = regrouper les données en **k** groupes
 - Maximiser la similarité entre objets à l'intérieur d'un groupe
 - Minimiser la similarité entre les objets des groupes
- Un individu appartient à un seul cluster



K-means



Objectif : partitionner cette population en 2 groupes ($k=2$)

Quels sont les éventuels groupes?

K-means

- Algorithme de k-means :

- 1- Choisir k objets formant ainsi k clusters C_i ; quelque soit i entier naturel $0 < i < k+1$
- 2- Affecter chaque objet O au cluster C_i de centre M_i telle que la distance en O et M_i est minimale
- 3- Calculer M_i de chaque cluster C_i
- 4- Répéter les étapes 2- et 3-
- 5- Arrêt si pas de changement

K-means

- Exemple 1 :

Soit le corpus $D=\{1, 2, 3, 6, 7, 8, 13, 15, 17\}$

Appliquer l'algorithme k-means pour partitionner l'ensemble D en 3 clusters

Initialisation : prendre 3 objets au hasard 1, 2 et 3 $M_1=1$, $M_2=2$ et $M_3=3$

Similarité : $d(a,b) = |a-b|$

K-means

- Exemple 1 :

Soit le corpus $D=\{1, 2, 3, 6, 7, 8, 13, 15, 17\}$

Appliquer l'algorithme k-means pour partitionner l'ensemble D en 3 clusters

Initialisation : prendre 3 objets au hasard 1, 2 et 3 $M_1=1$, $M_2=2$ et $M_3=3$

Similarité : $d(a,b) = |a-b|$

Résultat :

$C1=\{1, 2, 3\}$

$C2=\{6, 7, 8\}$

$C3=\{13, 15, 17\}$

À quels groupes appartiennent les objets 18, 4, 14?

K-means


- Exemple 2 :

Soit le corpus D composé des points A1, A2, A3, A4, A5, A6, A7 et A8.

Les objets marqués en rouge représentent une initialisation des centroïdes.

Partitionner en groupes l'ensemble D en appliquant l'algorithme k-means

Montrer l'évolution des groupes en fonction des itérations d'applications de k-means



K-means

- Exemple 3 :

Soit le corpus $D = \{OB-1, OB-2, OB-3, OB-4, OB-5, OB-6, OB-7, OB-8\}$.

Partitionner en 2 groupes

Points	X	Y	Z
OB-1	1	4	1
OB-2	1	2	2
OB-3	1	4	2
OB-4	2	1	2
OB-5	1	1	1
OB-6	2	4	2
OB-7	1	1	2
OB-8	2	1	1

K-means

- k-means = regrouper les données en **k** groupes d'individus les plus semblables possibles
 - k petit => grands groupes
 - k grand => petits groupes

K-means

- Avantages
 - Classification rapide d'une nouvelle instance
- Inconvénients
 - Nombre de groupe k ?
 - Initialisation idéale des centroïdes pour une convergence rapide ?
 - Valeurs d'attributs non numériques